



ECHOCeM: THIRD INTERFACE ECHO SEGMENTATION FOR CEMENT QUALITY ASSESSMENT

DATA CHALLENGE DE DEEP

Auteurs: Víctor Camps Abarca
Aldric Bahna

Professeurs: Bertrand Michel
Didier Lime

NANTES, 16 JANVIER 2026

Table des matières

1	Introduction	1
1.1	Contexte	1
1.2	Equipe	1
2	Exploration des données	1
2.1	Format des données	1
2.2	Distribution et déséquilibre des données	1
2.3	Pipeline de prétraitement et justification des techniques	2
3	Construction du modèle de référence : UNet	3
3.1	Motivations	3
3.2	Architecture générale	3
4	Premier modèle	4
5	Conclusion	4

Table des figures

1	Distribution des classes dans le dataset	2
2	Pipeline complet de prétraitement : Original → Redimensionné → Normalisé . .	3

Liste des tableaux

1 Introduction

1.1 Contexte

Les données étudiées dans ce travail sont constituées d'images ultrasonores acquises lors d'inspections de puits, représentant des coupes radiales du tubage, du ciment et de la formation environnante. Ces images, caractérisées par une forte variabilité spatiale et un niveau de bruit significatif, contiennent une information indirecte mais essentielle sur l'état du ciment, dont la qualité conditionne l'intégrité mécanique et la sécurité du puits. L'enjeu est d'exploiter ces données pour identifier automatiquement, au niveau du pixel, des interfaces physiques clés, en particulier la troisième interface d'écho entre le ciment et la formation géologique. Le problème est formulé comme une tâche de segmentation supervisée d'images, dans laquelle un modèle d'apprentissage automatique doit apprendre à associer à chaque pixel une classe correspondant à une structure physique donnée. L'objectif de ce travail est ainsi de concevoir un pipeline de détection des segmentations, robuste et généralisable, évaluée à l'aide de métriques standard de segmentation (Intersection Over Union IOU), afin de fournir une estimation fiable et automatisée de la qualité du ciment à partir des données ultrasonores.

1.2 Equipe

Nous sommes deux alternants en 3e année à l'école Centrale de Nantes, en option Informatique pour l'intelligence artificielle. Nous avons fait la totalité de ce Datachallenge en période entreprise.

2 Exploration des données

2.1 Format des données

Le dataset d'entraînement contient **4410 patches d'images** provenant de 4 puits distincts (puits 2, 3, 4, 5 et 6). Chaque image est représentée sous forme vectorisée aplatie contenant **43520 pixels**, correspondant à des dimensions originales de 160×272 pixels. Les données d'étiquetage sont des classes de segmentation sémantique multi-classe : **Background** (classe 0), **Casing** (classe 1) et **TIE** (classe 2).

Cependant, le dataset présente une **hétérogénéité dimensionnelle** : certaines images ont des dimensions de 160×160 pixels tandis que d'autres sont en 160×272 pixels. Pour harmoniser le traitement et s'adapter aux exigences des architectures de réseau de neurones convolutifs, une décision de **normalisation spatiale à 160×160 pixels** a été prise. Le redimensionnement est effectué via la bibliothèque **OpenCV** avec interpolation linéaire **INTER_LINEAR**, offrant un excellent compromis entre qualité et performance computationnelle, et améliorant la précision offerte par l'approche du benchmark.

2.2 Distribution et déséquilibre des données

L'analyse du dataset révèle un **déséquilibre significatif** selon deux dimensions critiques pour l'entraînement des modèles.

Déséquilibre par puits : La répartition des patches n'est pas uniforme entre les puits. Les puits 2 et 6 contiennent respectivement environ 1600 et 1500 patches, tandis que le puits 4

en contient environ 600, et le puits 5 seulement 300. Cela représente un **ratio déséquilibré de 1 :5** entre le puits le moins et le plus représenté. Ce déséquilibre peut introduire un biais dans l'entraînement, où les caractéristiques géologiques spécifiques aux puits surreprésentés seraient surpondérées au détriment des autres.

Déséquilibre par classe : Le problème est encore plus prononcé au niveau des classes de segmentation. L'analyse des pixels révèle une distribution fortement imbriquée : la classe **Background** représente environ **85%** des pixels totaux, tandis que **Casing** en représente 9% et **TIE** seulement 6%.




FIGURE 1 – Distribution des classes dans le dataset

Ce déséquilibre extrême (ratio d'environ 15 :1 entre les classes majoritaires et minoritaires) pose un défi majeur pour l'apprentissage supervisé : un modèle naïf pourrait atteindre 85% de précision en prédisant Background sur tous les pixels, sans capturer les structures d'intérêt.

Ces observations justifient l'implémentation de **techniques de correction du déséquilibre** : l'application de **poids de classe** (class weights) pour pénaliser davantage les erreurs sur les classes minoritaires, l'utilisation de **data augmentation** pour augmenter virtuellement la diversité des données, et l'adoption de fonctions de perte spécialisées comme **Focal Loss** qui amplifient l'apprentissage sur les échantillons difficiles.

2.3 Pipeline de prétraitement et justification des techniques

Le pipeline de prétraitement implémenté suit quatre étapes essentielles pour préparer les données brutes à l'entraînement des réseaux de neurones.

Redimensionnement spatial : Toutes les images sont redimensionnées à la dimension uniforme de 160×160 pixels via **OpenCV** avec interpolation linéaire. Cette étape est cruciale car les architectures CNN exigent des dimensions d'entrée fixes et les images carrées offrent une symétrie géométrique bénéfique pour l'extraction de features.

Le choix de la méthode d'interpolation est **critique et différencié selon le type de données**. Pour les **images d'intensité**, on utilise l'interpolation **INTER.LINEAR** (bilinéaire), qui interpole les valeurs intermédiaires entre pixels pour créer des transitions lisses. Cette approche préserve les détails fins du contenu informatif et produit une image de meilleure qualité pour l'apprentissage du réseau. En revanche, pour les **masques de segmentation** contenant des classes discrètes (0, 1, 2), on utilise l'interpolation **INTER.NEAREST** (plus proche voisin), qui garantit que chaque pixel redimensionné reste une classe valide. Utiliser **INTER.LINEAR** sur

les masques créerait des valeurs fractionnaires invalides (0.5, 1.3, etc.), corrompant les étiquettes. Cette distinction méthodologique assure une cohérence sémantique : les images conservent leurs variations d'intensité lisses tandis que les labels de classe demeurent **entiers et valides** après redimensionnement.

Gestion des valeurs manquantes : Lors du redimensionnement, certaines opérations d'interpolation peuvent générer des valeurs NaN. Ces valeurs sont détectées et remplacées par 0 (correspondant à des intensités nulles) pour assurer l'intégrité des données sans perturber significativement le contenu informatif des images.

Normalisation min-max : Les intensités de pixels, initialement dans leur plage brute, sont normalisées à l'intervalle $[0, 1]$ selon la formule $\tilde{x} = \frac{x - x_{min}}{x_{max} - x_{min}}$. Cette normalisation est **critique pour la convergence numérique** des réseaux de neurones : elle assure que les gradients restent dans des plages numériquement stables et que l'initialisation des poids est appropriée aux magnitudes d'entrée.

Voici un exemple illustré :




FIGURE 2 – Pipeline complet de prétraitement : Original → Redimensionné → Normalisé

3 Construction du modèle de référence : UNet

3.1 Motivations

3.2 Architecture générale

Data augmentation en entraînement : Au-delà de ce pipeline de base, une **data augmentation** est appliquée dynamiquement durant l'entraînement. Compte tenu du déséquilibre observé (seulement 4410 patches pour un problème complexe de segmentation multi-classe), les techniques d'augmentation géométrique (rotations, flips, décalages) augmentent virtuellement la taille effective du dataset et améliorent la robustesse du modèle face à des variations spatiales non vues lors de l'entraînement. Cela contribue à réduire le surapprentissage et améliore la généralisation.

Poids de classe (class weights) : Pour contrer le déséquilibre class majeur (95% vs 1% vs 1%), des poids de classe sont calculés de manière inversement proportionnelle à la fréquence de chaque classe. Ces poids sont intégrés à la fonction de perte (Cross-Entropy Loss pondérée) pour que le modèle accorde une **importance disproportionnée** aux pixels rares. De cette

manière, une erreur de segmentation sur la classe TIE (minoritaire) pénalise davantage le modèle qu'une erreur équivalente sur Background (majoritaire) , alignant les objectifs d'optimisation avec l'importance pratique des classes.

4 Premier modèle

5 Conclusion